

TECNOLOGIA EM BANCO DE DADOS – 2026

Análise de Desempenho de Clubes no Campeonato Brasileiro ao Longo do Tempo

DISCIPLINA: PROJETO APLICADO I – BANCO DE DADOS – 2026.1

Grupos de Projeto Aplicado I – BD – 2A 5:

DANIEL SILVA SOUZA FILHO

RA: **10737593**

DAVI MAGLIARI DA PURIFICAÇÃO PEREIRA

RA: **10750242**

SUMÁRIO

1. Introdução.....	3
2. Glossário.....	3
3. Objetivo do Estudo.....	4
4. Apresentação do Contexto do Estudo.....	4
5. Problema de Pesquisa.....	5
6. Metadados.....	5
I. Identificação do Dataset.....	5
II. Caracterização.....	6
III. Principais Atributos.....	6
IV. Tipos de Dados.....	6
7. Análise Exploratória de Dados (AED).....	6
I. Estrutura dos Dados.....	6
II. Estatísticas Descritivas.....	7
III. Análise de Frequência.....	7
IV. Valores Ausentes e Inconsistências.....	7
V. Análise de Distribuição.....	7
8. Proposta de Solução Analítica.....	7
9. Scripts Python (AED).....	8
I. Importação das bibliotecas.....	8
II. Carregamento da base.....	8
III. Verificação de valores nulos.....	9
IV. Definição das colunas principais.....	9
V. Criação da coluna de resultado.....	9
VI. Estatísticas descritivas.....	9
VII. Gráfico de frequência dos resultados.....	9
VIII. Histograma de gols do mandante.....	10
IX. Análise por temporada.....	10
X. Comparação mandante vs visitante.....	10
Referências:.....	12

Análise de Desempenho de Clubes no Campeonato Brasileiro ao Longo do Tempo

DANIEL SILVA SOUZA FILHO

DAVI MAGLIARI DA PURIFICAÇÃO PEREIRA

ETAPA 2 – DEFINIÇÃO DO PRODUTO ANALÍTICO

1. Introdução

Esta etapa tem como objetivo apresentar a proposta de solução analítica do projeto, bem como realizar a análise exploratória de dados (AED) a partir de um conjunto de dados reais. A análise exploratória é fundamental para compreender a estrutura dos dados, identificar padrões e verificar a qualidade das informações disponíveis, servindo como base para decisões posteriores no projeto.

2. Glossário

- **Dataset:** conjunto estruturado de dados organizados em linhas e colunas.
- **Análise Exploratória de Dados (AED):** etapa inicial da análise, que visa compreender os dados por meio de estatísticas descritivas, identificação de padrões, valores ausentes e possíveis inconsistências.
- **Metadados:** informações que descrevem o dataset, como origem, tipo de arquivo e características das variáveis.
- **Outliers:** valores atípicos que fogem significativamente do padrão dos dados.

- **Variáveis categóricas:** representam categorias (ex.: nome do time).
- **Variáveis numéricas:** representam valores quantitativos (ex.: número de gols).

3. Objetivo do Estudo

O objetivo deste estudo é analisar dados históricos do Campeonato Brasileiro, com o intuito de identificar padrões de desempenho dos clubes ao longo do tempo.

Busca-se compreender aspectos como:

- desempenho das equipes como mandantes e visitantes;
- distribuição de gols nas partidas;
- frequência de resultados (vitória, empate e derrota);
- regularidade dos clubes ao longo das temporadas.

A análise visa transformar dados brutos em informações relevantes que possam apoiar interpretações mais objetivas sobre o comportamento do campeonato.

4. Apresentação do Contexto do Estudo

O presente estudo está inserido no contexto do Campeonato Brasileiro Série A, uma das principais competições esportivas do país. Trata-se de um ambiente altamente competitivo, que envolve múltiplos clubes, grande volume de dados e forte interesse público.

Embora não se trate de uma empresa tradicional, o campeonato pode ser analisado como um sistema organizacional, no qual diferentes entidades (clubes) competem entre si ao longo de várias temporadas.

Esse contexto permite a aplicação de técnicas de Ciência de Dados para análise de desempenho, identificação de padrões e compreensão da dinâmica da competição.

5. Problema de Pesquisa

O problema central deste estudo consiste em identificar quais padrões podem ser extraídos dos dados históricos do Campeonato Brasileiro e como esses padrões ajudam a explicar o desempenho das equipes.

Dessa forma, busca-se responder às seguintes questões:

- Existe vantagem significativa para equipes que jogam em casa?
- Como se comporta a distribuição de gols nas partidas?
- Há padrões de desempenho que se repetem ao longo das temporadas?
- Quais clubes apresentam maior regularidade?

A abordagem adotada baseia-se no pensamento computacional, envolvendo decomposição do problema, identificação de padrões, abstração e utilização de algoritmos para análise dos dados.

6. Metadados

I. Identificação do Dataset

- **Nome:** Brasileirão – Dados Históricos
- **Fonte:** Kaggle
- **Formato:** .CSV
- **Origem:** Dados abertos

II. Caracterização

- Não possui dados sensíveis
- Uso voltado para análise acadêmica
- Representa partidas de diferentes temporadas do campeonato

III. Principais Atributos

- Temporada
- Rodada
- Time mandante
- Time visitante
- Gols do mandante
- Gols do visitante
- Resultado da partida

IV. Tipos de Dados

- Categóricos: times, resultados
- Numéricos: gols, rodada, temporada

7. Análise Exploratória de Dados (AED)

A análise exploratória de dados tem como finalidade compreender a estrutura do dataset e extrair informações iniciais relevantes.

I. Estrutura dos Dados

- número de registros (linhas);
- número de variáveis (colunas);

- tipos de dados de cada coluna

II. Estatísticas Descritivas

- média;
- valores mínimo e máximo;
- desvio padrão.

Essas medidas permitem compreender a distribuição dos dados, especialmente em relação ao número de gols por partida.

III. Análise de Frequência

- frequência de resultados (vitória, empate, derrota);
- distribuição de jogos por temporada.

IV. Valores Ausentes e Inconsistências

- valores nulos;
- dados duplicados;

V. Análise de Distribuição

- distribuição de gols;
- comportamento dos resultados;
- comparação entre mandantes e visitantes.

8. Proposta de Solução Analítica

A proposta deste projeto consiste em desenvolver uma análise estruturada do Campeonato Brasileiro, transformando dados históricos em informações relevantes sobre o desempenho das equipes.

O produto analítico será composto por:

- estatísticas descritivas do campeonato;
- análise comparativa entre clubes;
- avaliação do fator casa;
- análise da distribuição de gols;
- visualizações que facilitem a interpretação dos dados.

O objetivo final é demonstrar que, por meio da análise de dados, é possível compreender melhor os padrões do futebol, reduzindo a subjetividade e tornando as análises mais fundamentadas.

9. Scripts Python (AED)

I. Importação das bibliotecas

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np
```

II. Carregamento da base

```
df = pd.read_csv("data/raw/brasileirao.csv")

print("Dimensão da base:")
print(df.shape)
```



```
print("\nColunas:")  
print(df.columns)
```

```
print("\nPrimeiras linhas:")  
print(df.head())
```

III. Verificação de valores nulos

```
print("\nValores nulos:")  
print(df.isnull().sum())
```

IV. Definição das colunas principais

```
gols_mandante = "gols_mandante"  
gols_visitante = "gols_visitante"  
temporada = "temporada"
```

V. Criação da coluna de resultado

```
df["resultado"] = np.where(  
    df[gols_mandante] > df[gols_visitante], "Mandante",  
    np.where(df[gols_mandante] < df[gols_visitante], "Visitante", "Empate")  
)  
print("\nFrequência de resultados:")  
print(df["resultado"].value_counts())
```

VI. Estatísticas descritivas

```
print("\nEstatísticas dos gols:")  
print(df[[gols_mandante, gols_visitante]].describe())
```

VII. Gráfico de frequência dos resultados

```
df["resultado"].value_counts().plot(kind="bar")
plt.title("Resultados das Partidas")
plt.xlabel("Resultado")
plt.ylabel("Quantidade")
plt.tight_layout()
plt.show()
```

VIII. Histograma de gols do mandante

```
plt.hist(df[gols_mandante], bins=10)
plt.title("Gols do Mandante")
plt.xlabel("Gols")
plt.ylabel("Frequência")
plt.tight_layout()
plt.show()
```

IX. Análise por temporada

```
media_temporada = df.groupby(temporada)[gols_mandante, gols_visitante].mean()
```

```
print("\nMédia de gols por temporada:")
print(media_temporada)
```

```
media_temporada.plot()
plt.title("Média de Gols por Temporada")
plt.xlabel("Temporada")
plt.ylabel("Média de gols")
plt.tight_layout()
plt.show()
```

X. Comparação mandante vs visitante

```
print("\nMédia geral de gols do mandante:", df[gols_mandante].mean())
```

```
print("Média geral de gols do visitante:", df[gols_visitante].mean())
```

Referências:

GUSTAVOMARTINO. Brasileiro. Kaggle, [s.d.]. Disponível em: <https://www.kaggle.com/datasets/gustavomartino/brasileirao>. Acesso em: 20 mar. 2026.

GOLDSCHMIDT, Ronaldo; BEZERRA, Eduardo. Data mining: conceitos, técnicas, algoritmos, orientações e aplicações. 2. ed. Rio de Janeiro: Elsevier, 2015.